

Auto-correlation et régression spatiales

Objectifs Réaliser une étude d'auto-corrélation spatiale et une modélisation linéaire spatiale avec le logiciel utilisé est **R** et ses packages *spdep*, *spatialreg* et *fields*.

Données

Les espèces épibenthiques (qui vivent sur les fonds marins) sont des biomarqueurs de l'état environnemental et des sources d'alimentation des poissons de la baie du Saint Laurent. Depuis plusieurs années des campagnes scientifiques sont menées pour mesurer la biomasse de ces espèces. Le Golfe du Saint Laurent est découpé en strates de milieux homogènes.


Le fichier StLaurent.csv contient pour l'année 2000 les valeurs des variables suivantes :

strate : numéro de la strate
longitude : longitude du centre de la strate
latitude : latitude du centre de la strate
BH : présence (1) absence (0) de bernard l'ermite Le fichier "boundaries38s.dat" donne pour
totconsum : indice de prédation
depth : profondeur
temperature : température

les 38 strates les coordonnées des points formant les bords :

colonne 1 : numéro de la strate (de 401 à 438)
colonne 2 : longitude du point
colonne 3 : latitude du point

strate	longitude	latitude	BH
Min. : 1.00	Min. : -65.56	Min. : 45.83	Min. : 0.0000
1st Qu.: 10.25	1st Qu.: -63.57	1st Qu.: 46.85	1st Qu.: 0.0000
Median : 19.50	Median : -62.74	Median : 47.45	Median : 1.0000
Mean : 19.50	Mean : -62.75	Mean : 47.36	Mean : 0.6579
3rd Qu.: 28.75	3rd Qu.: -61.78	3rd Qu.: 47.96	3rd Qu.: 1.0000
Max. : 38.00	Max. : -60.49	Max. : 48.85	Max. : 1.0000
totconsum	depth	temperature	
Min. : 0.02763	Min. : 17.50	Min. : -0.1750	
1st Qu.: 0.10862	1st Qu.: 35.48	1st Qu.: 0.7264	
Median : 0.20314	Median : 54.85	Median : 2.2900	
Mean : 0.22550	Mean : 75.99	Mean : 3.9179	
3rd Qu.: 0.27933	3rd Qu.: 69.11	3rd Qu.: 5.4694	
Max. : 0.69466	Max. : 295.90	Max. : 15.8333	




1 Auto-corrélation spatiale

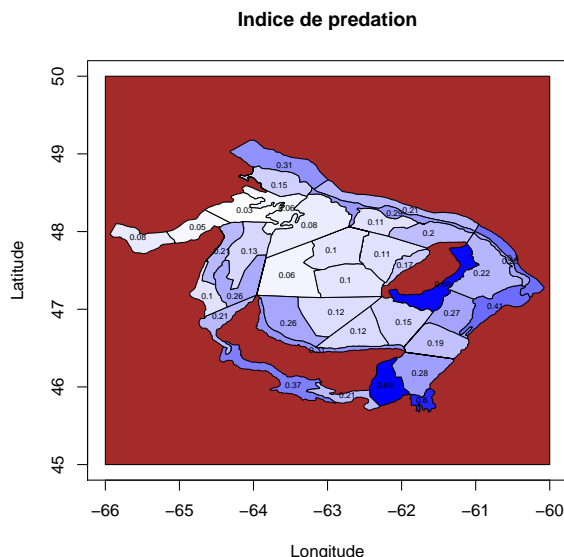
L'autocorrélation spatiale mesure la corrélation d'une variable avec elle-même, lorsque les observations sont décalées dans l'espace.

Pour obtenir l'auto-corrélation et réaliser un test d'autocorrélation, il faut spécifier une matrice de poids W . On cherche une matrice de voisinage permettant de décrire de manière adéquate les relations entre les entités géographiques tout en estimant un modèle de régression identifiable (choix pas toujours facile).

Des indices d'autocorrélation spatiale (Moran ou Geary) évaluent la dépendance spatiale d'une même variable en différents sites et teste la significativité de la structure spatiale identifiée. Ils s'intéressent à la proximité spatiale et à la ressemblance ou dissemblance des sites étudiés.



1.1 Indice de Moran ou Geary




2 Diagramme de Moran

Le diagramme de Moran (nuage de points entre les valeurs de la variable Z étudiée centrée et valeurs moyennes de la variable pour les observations voisines (WZ) en ordonnée, avec W la matrice de poids normalisée) permet une lecture rapide de la structure spatiale. A ce nuage, on ajoute la droite de régression linéaire de WZ par Z , les droites $Z = 0$ et $WZ = 0$ qui délimitent 4 quadrants.

Si la répartition des données est aléatoire, pas de relation particulière entre Z et WZ (répartition uniforme dans les quadrants). Sinon, la pente de la régression linéaire est non nulle ; chaque quadrant donne un type d'association spatiale. Ce diagramme permet également de relever les sites les plus atypiques, loins de la structure spatiale étudiée.

- Le quadrant 1 (en haut à droite) donne des valeurs de Y plus grandes que la moyenne, dans un voisinage qui leur ressemblent (autocorrélation positive et indice élevé).
- Le quadrant 2 (en bas à droite) donne des valeurs de Y plus grandes que la moyenne, dans un voisinage qui ne leur ressemble pas (autocorrélation négative et indice élevé).
- Le quadrant 3 (en bas à gauche) donne des valeurs de Y plus faibles que la moyenne, dans un voisinage qui leur ressemble (autocorrélation positive et indice faible).
- Le quadrant 4 (en haut à gauche) donne des valeurs de Y plus faibles que la moyenne, dans un voisinage qui ne leur ressemble pas (autocorrélation négative et indice faible).



Le diagramme précédent met en évidence une structure spatiale particulière (cadrants 1, 3 et 4). On calcule donc l'indice d'autocorrélation spatiale et effectue un test afin de répondre à la question : 1) les observations voisines sont-elles sensibles ou pas par hasard ? Si la réponse est non il y a de l'autocorrélation

spatiale mais dans quel sens. On teste la nullité de l'indice sous l'hypothèse de normalité des données ou non (dans ce dernier cas on utilise la randomisation; la statistique des observations est comparée à la distribution obtenue en permutant au hasard les données).

Le programme suivant montre qu'il y a une auto-corrélation spatiale positive (indice de Moran positive et hypothèse de nullité de l'indice rejetée) avec un seul décalage.

Moran I test under randomisation

data: totconsumred\$totconsumred

weights: poids.vois

Moran I statistic standard deviate = 3.9927, p-value = 3.267e-05

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.175289338	-0.027027027	0.002567662

Moran I test under randomisation

data: totconsum

weights: poids.vois

Moran I statistic standard deviate = 3.9927, p-value = 3.267e-05

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.175289338	-0.027027027	0.002567662

Moran I test under normality

data: totconsum

weights: poids.vois

Moran I statistic standard deviate = 3.8743, p-value = 5.346e-05

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.175289338	-0.027027027	0.002726872

Monte-Carlo simulation of Moran I

data: totconsum

weights: poids.vois

number of simulations + 1: 100

statistic = 0.17529, observed rank = 100, p-value = 0.01

alternative hypothesis: greater

Calcul des intervalles de l'indice de Moran :

[1] -0.3545677 1.0195219

Indice de Geary : montre également une autocorrélation spatiale positive (indice plus petite que 1)

Monte-Carlo simulation of Geary C

data: totconsum

weights: poids.vois

number of simulations + 1: 100

statistic = 0.77677, observed rank = 1, p-value = 0.01

alternative hypothesis: greater

Geary C test under randomisation

data: totconsum

weights: poids.vois

Geary C statistic standard deviate = 3.301, p-value = 0.0004816

alternative hypothesis: Expectation greater than statistic

```

sample estimates:
Geary C statistic      Expectation      Variance
      0.776772218      1.000000000      0.004572916
      Geary C test under normality

```

```

data: totconsum
weights: poids.vois

```

```

Geary C statistic standard deviate = 3.7115, p-value = 0.000103
alternative hypothesis: Expectation greater than statistic

```

```

sample estimates:
Geary C statistic      Expectation      Variance
      0.77677222      1.00000000      0.00361743

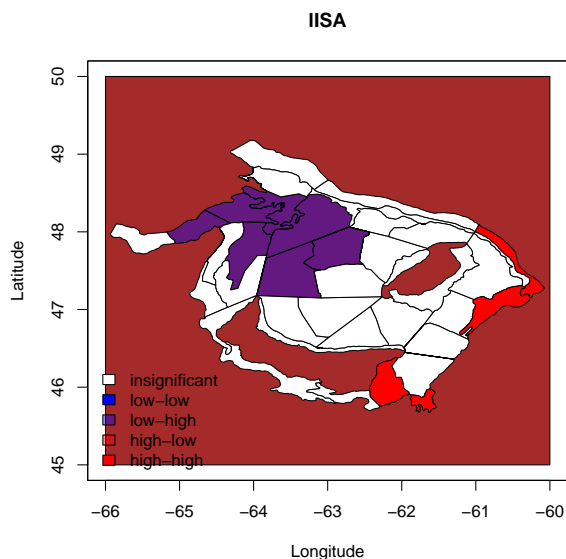
```

2.1 Autocorrélation spatiale locale

Les indices précédents mesurent l'autocorrélation globale, pour étudier l'autocorrélation spatiale locale (LISA ; Local Indicators of Spatial Association), des versions locales des indices précédents existents et permettent de mesurer pour une variable donnée la dépendance locale entre une unité spatiale et les unités spatiales voisines. Ils permettent d'identifier les regroupements similaires autour d'un site donné et les zones de non-stationnarité spatiale locale.

L'Indice de Moran locale en un site i est :

$$I_i = \sum_j w_{ij} (Z_j - \bar{Z})(Z_i - \bar{Z})$$



3 Régression spatiale

3.1 Modèle linéaire

```

Call:
lm(formula = totconsum ~ temperature + depth)

```

```

Residuals:
      Min       1Q   Median       3Q      Max
-0.26612 -0.06910 -0.01072  0.06687  0.32157

```

```

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.1028305   0.0381121   2.698  0.0107 *
temperature  0.0259357   0.0050844   5.101 1.18e-05 ***
depth        0.0002771   0.0003021   0.917  0.3652
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1258 on 35 degrees of freedom
Multiple R-squared: 0.4272, Adjusted R-squared: 0.3945
F-statistic: 13.05 on 2 and 35 DF, p-value: 5.817e-05
Analysis of Variance Table

Response: totconsum

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
temperature	1	0.39986	0.39986	25.2645	1.481e-05 ***
depth	1	0.01332	0.01332	0.8417	0.3652
Residuals	35	0.55394	0.01583		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Call:

lm(formula = totconsum ~ temperature)

Residuals:

Min	1Q	Median	3Q	Max
-0.27395	-0.06573	-0.01683	0.06186	0.31137

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.126135	0.028351	4.449	7.98e-05 ***
temperature	0.025363	0.005035	5.037	1.34e-05 ***

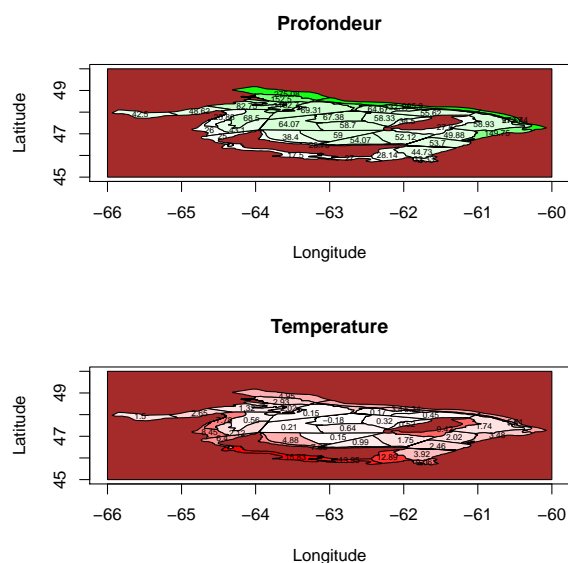
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1255 on 36 degrees of freedom
Multiple R-squared: 0.4135, Adjusted R-squared: 0.3972
F-statistic: 25.38 on 1 and 36 DF, p-value: 1.34e-05
Analysis of Variance Table

Response: totconsum

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
temperature	1	0.39986	0.39986	25.376	1.34e-05 ***
Residuals	36	0.56727	0.01576		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1



3.2 Modèle SAR

$$Z = \rho WZ + X\beta + \varepsilon,$$

$\varepsilon \sim N(0, \sigma^2)$, ou pas $(I - \rho W)$ inversible

```
Call:lagsarlm(formula = totcons.lm, listw = poids.vois, type = "lag",
  method = "eigen")
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.307128	-0.055084	-0.010262	0.034457	0.316731

Type: lag

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.0247105	0.0515772	0.4791	0.6319
temperature	0.0234929	0.0047247	4.9724	6.613e-07

Rho: 0.5196, LR test value: 4.3249, p-value: 0.037558

Asymptotic standard error: 0.22894

z-value: 2.2696, p-value: 0.02323

Wald statistic: 5.1512, p-value: 0.02323

Log likelihood: 28.12851 for lag model

ML residual variance (sigma squared): 0.012969, (sigma: 0.11388)

Number of observations: 38

Number of parameters estimated: 4

AIC: -48.257, (AIC for lm: -45.932)

LM test for residual autocorrelation

test value: 0.31833, p-value: 0.57261

Moran I test under randomisation

data: res

weights: poids.vois


Moran I statistic standard deviate = 0.86453, p-value = 0.1936

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.017065351	-0.027027027	0.002601188

Residus modele SAR a retard



Interprétation du modèle : dans un modèle linéaire classique, l'impact d'une variation d'une variable explicative sur la réponse est égale au coefficient correspondant (dérivée partielle de la réponse en fonction de la variable explicative).

Dans ce modèle SAR ; les éléments diagonaux de la matrice des dérivées partielles de z_i par rapport à x_i représentent les impacts directs qui incluent les effets de spillovers (réverbérations) propres, hétérogènes pour chaque observation en présence d'autocorrélation spatiale, dus aux poids différents de la matrice d'interactions. Les éléments hors-diagonaux représentent les impacts indirects ou effets de spillovers (collectés dans la matrice) ils quantifient les effets globaux (sur tout l'échantillon). En sommant les impacts directs (resp. indirects), on obtient l'impact total direct (resp indirect).

```
[1] 0.02472291 0.02475493 0.02476920 0.02468111 0.02461042 0.02453486
[7] 0.02475523 0.02471041 0.02467303 0.02459006
[1] 0.02424721
      [,1]
[1,] 0.02465551
      [,1]
[1,] 0.04890272
```

3.3 Modèle SEM

Autocorrélation des résidus (modèle SEM) : $Z = \rho W X + X\beta + \varepsilon$, avec hypothèse de normalité $\varepsilon \sim N(0, \sigma^2)$ ou non

Global Moran I for regression residuals

data:

model: `lm(formula = totconsum ~ temperature)`

weights: `poids.vois`

Moran I statistic standard deviate = 4.8907, p-value = 5.023e-07

alternative hypothesis: greater

sample estimates:

Observed Moran I	Expectation	Variance
0.216121473	-0.031968887	0.002573186

Moran I test under randomisation

data: `res0`

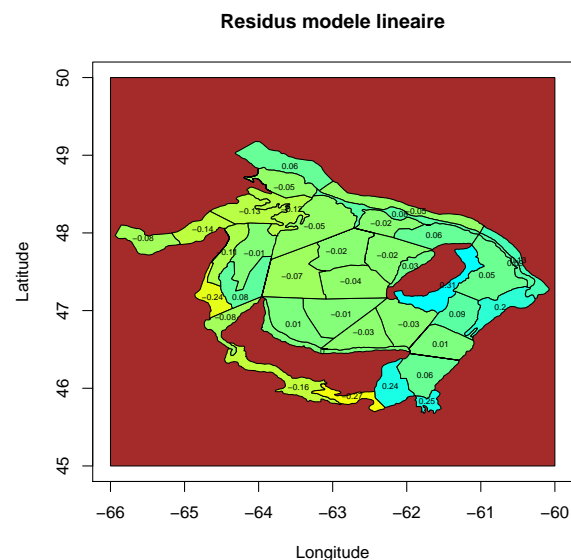
weights: `poids.vois`

Moran I statistic standard deviate = 4.6978, p-value = 1.315e-06

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
0.216121473	-0.027027027	0.002678911



On accepte l'existence d'une auto-corrélation positive


```
Call:errorsarlm(formula = totconsum ~ temperature, data = donnees,
  listw = poids.vois)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.2990746	-0.0498816	-0.0059529	0.0366786	0.2841549

Type: error

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.1291709	0.0501543	2.5755	0.01001
temperature	0.0257756	0.0048375	5.3283	9.913e-08

Lambda: 0.59644, LR test value: 5.5791, p-value: 0.018176

Asymptotic standard error: 0.21997

z-value: 2.7115, p-value: 0.006698

Wald statistic: 7.3522, p-value: 0.006698

Log likelihood: 28.75558 for error model

ML residual variance (sigma squared): 0.012413, (sigma: 0.11142)

Number of observations: 38

Number of parameters estimated: 4

AIC: -49.511, (AIC for lm: -45.932)

Moran I test under randomisation

data: res1

weights: poids.vois

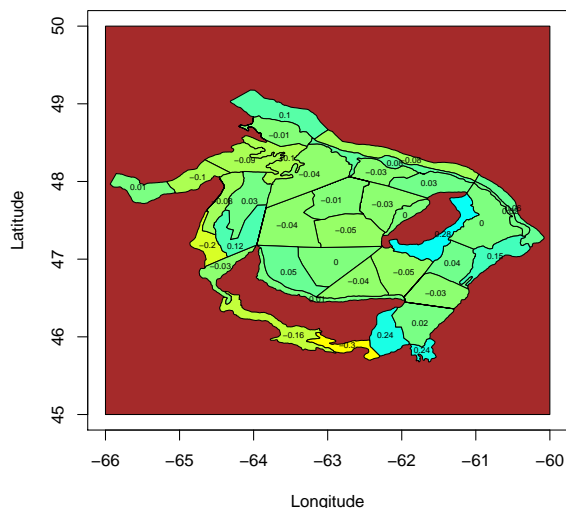
Moran I statistic standard deviate = 0.096528, p-value = 0.4616

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
-0.022090961	-0.027027027	0.002614879

Residus modele SAR sur les erreurs



-0.2912936 -0.0469297 -0.0072158 0.0394243 0.2748867

Type: mixed

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.0683143	0.0617441	1.1064	0.2685
temperature	0.0263167	0.0051316	5.1283	2.923e-07
lag.temperature	-0.0204269	0.0175523	-1.1638	0.2445

Rho: 0.59134, LR test value: 5.4494, p-value: 0.019576

Asymptotic standard error: 0.22203

z-value: 2.6633, p-value: 0.0077381

Wald statistic: 7.0931, p-value: 0.0077381

Log likelihood: 28.80455 for mixed model

ML residual variance (sigma squared): 0.012391, (sigma: 0.11132)

Number of observations: 38

Number of parameters estimated: 5

AIC: -47.609, (AIC for lm: -44.16)

LM test for residual autocorrelation

test value: 1.392, p-value: 0.23806

Moran I test under randomisation

data: res3

weights: poids.vois

Moran I statistic standard deviate = 0.080123, p-value = 0.4681

alternative hypothesis: greater

sample estimates:

Moran I statistic	Expectation	Variance
-0.022922531	-0.027027027	0.002624225

Call: lagsarlm(formula = totcons.sarlm, data = donnees, listw = poids.vois,
type = "lag", method = "eigen")

Residuals:

Min	1Q	Median	3Q	Max
-0.2912936	-0.0469297	-0.0072158	0.0394243	0.2748867

Type: lag

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.0683143	0.0617441	1.1064	0.2685
temperature	0.0263167	0.0051316	5.1283	2.923e-07
Wtemperature	-0.0204269	0.0175523	-1.1638	0.2445

Rho: 0.59134, LR test value: 5.4494, p-value: 0.019576

Asymptotic standard error: 0.22203

z-value: 2.6633, p-value: 0.0077381

Wald statistic: 7.0931, p-value: 0.0077381

Log likelihood: 28.80455 for lag model

ML residual variance (sigma squared): 0.012391, (sigma: 0.11132)

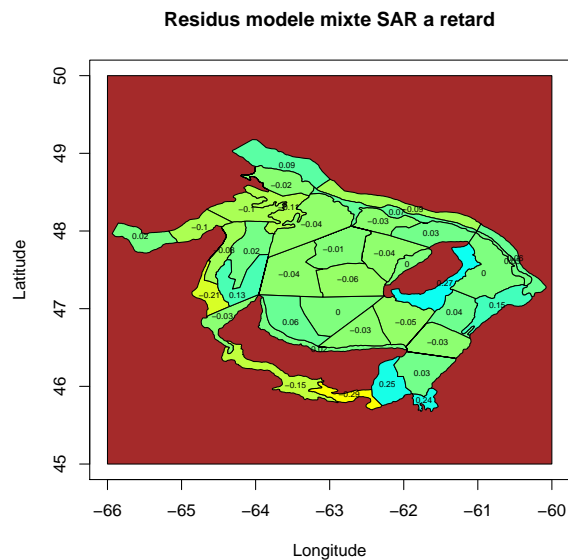
Number of observations: 38

Number of parameters estimated: 5

AIC: -47.609, (AIC for lm: -44.16)

LM test for residual autocorrelation

test value: 1.392, p-value: 0.23806



Interpretation du modèle SDM

```
[1] 0.02593592
      [,1]
[1,] -0.01152341
      [,1]
[1,] 0.01441252
Impact measures (mixed, exact):
      Direct      Indirect      Total
temperature 0.02593592 -0.01152341 0.01441252
```

3.5 Modèle SLX

Modèle SLX : $Z = \rho W X + X\beta + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$, décalage spatial des variables explicatives

Call:

```
lm(formula = totcons.sarlm, data = donnees)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.26519	-0.06498	-0.01168	0.06715	0.29310

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.150851	0.061046	2.471	0.0185 *
temperature	0.026685	0.005851	4.561	6e-05 ***
Wtemperature	-0.008764	0.019111	-0.459	0.6494

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1269 on 35 degrees of freedom

Multiple R-squared: 0.417, Adjusted R-squared: 0.3836

F-statistic: 12.51 on 2 and 35 DF, p-value: 7.939e-05

3.6 Comparaison des modèles

Lagrange multiplier diagnostics for spatial dependence

data:

```
model: lm(formula = totconsum ~ temperature + depth)
```

```
weights: poids.vois
```

	statistic	parameter	p.value
LMerr	9.3736	1	0.002201 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Lagrange multiplier diagnostics for spatial dependence
data:
model: lm(formula = totconsum ~ temperature + depth)
weights: poids.vois

      statistic parameter  p.value
LMerr   9.373615          1 0.002201 **
LMlag   8.628057          1 0.003310 **
RLMerr  0.837464          1 0.360123
RLMlag  0.091906          1 0.761768
SARMA   9.465521          2 0.008802 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Lagrange multiplier diagnostics for spatial dependence

data:
residuals: residuals(totcons.lm)
weights: poids.vois

LMErr = 9.3736, df = 1, p-value = 0.002201
      Likelihood ratio for spatial linear models

data:
Likelihood ratio = 0.097937, df = 1, p-value = 0.7543
sample estimates:
      Log likelihood of totcons.mixte Log likelihood of totcons.errorsarlm
                        28.80455                        28.75558

      df      AIC
totcons.mixte    5 -47.60911
totcons.errorsarlm 4 -49.51117
totcons.lagsarlm  4 -48.25701
totcons.lm        4 -44.83518
totcons.slx       4 -44.15975

```